Python pandas入門

pandasとは

- Pythonのデータ解析支援ライブラリ
- Rのようなデータフレームというデータ形式

DataFrameとSeries

- DataFrame　　2次元表
- Series　　1次元表

indexとcolumn

- index　　行の名前
- column　　列の名前

Seriesはindexのみ。
indexは行番号（配列インデクス）、
columnはテーブルのカラム名のように使える。
ただし、index、columnとも重複を許す点に注意。

DataFrameの作成

```
>>> import pandas as pd
>>> df = pd.DataFrame([list('abcd'), list('1234'), list('+-*/')])
>>> df
   0  1  2  3
0  a  b  c  d
1  1  2  3  4
2  +  -  *  /
>>>
>>> df = df.T  # 行列反転
>>> df
   0  1  2
0  a  1  +
1  b  2  -
2  c  3  *
3  d  4  /
>>>
>>> df.columns = ['arph', 'num', 'ope']  # カラム設定
>>> df
  arph  num ope
0    a    1   +
1    b    2   -
2    c    3   *
3    d    4   /
```

CSVの入出力

```
>>> df.columns = list('あいう')
>>> df.to_csv('a.csv', index=False, encoding='CP932')  # CSV出力
>>>
>>> pd.read_csv('a.csv', index_col=None, encoding='CP932')  # CSV入力
   あ  い  う
0  a  1  +
1  b  2  -
2  c  3  *
3  d  4  /
```

pandas.DataFrame.from_csv()は後方互換性のために、残されている関数。オプション引数の既定値が異なる。pandas.read_csv()を使うことが推奨されており、オプション引数の数も多い。

行・列の抽出

```
>>> df.head(10)  # 先頭から10行
>>> df.iloc[:10]  # 先頭から10行
>>> df.ix[:10]  # インデクス10までの行を抽出
>>> df.ix[:, 1:3]  # 列順による抽出(2、3列目)
>>> df[['city', 'pop2010']]  # 列名による抽出
```

DataFrame.ixについて

- df.ix[<行の指定>, <列の指定>]
- 「:」は全部
- インデクスが非intの場合は行指定は行番号指定と判定される

条件抽出

```
>>> smr[smr['pop2050'] > smr['pop2010']*0.8]    # where pop2050 > pop2010 * 0.8
>>> smr[(10 < smr['ken']) & (smr['ken'] < 30)]  # where 10 < ken and  ken < 30
>>> smr[(smr['ken'] < 5) | (40 < smr['ken'])]   # where ken < 5 or 40 < ken

>>> smr[smr['name'].str.contains('.*京.*')]     # where name like ‘%京%’
>>> smr[~smr['name'].str.contains('.*京.*')]    # where name not like ‘%京%’

>>> smr.query("ken < 5 or 40 < ken”)            # query()を使った or 条件検索
```

データ加工

```
>>> df['ken'] = df['city'].apply(lambda s: int(s[:len(s) - 3]))  # 既存の列を編集して新しい列を作成
>>> df['pop2010'] = df['pop2010'].apply(lambda s: int(s))        # 数値型に変換

>>> df = pd.merge(df, prefs, on='ken')             # データフレームを結合  where t1.ken = t2.ken
>>> df.groupby(['ken', 'name'])['pop2010'].sum()  # 集約 sum(pop2010) … groupby ken, name
>>> df.groupby(['ken', 'name']).size()            # 集約 count() … groupby ken, name

>>> kens = df.drop_duplicates(['ken', 'name'])  # ユニーク化 select distinct ken, name
>>> kens.sort_values('ken')                     # ソート order by ken
```

集約結果を使ってデータ加工を継続するには

集約結果はSeriesで返される。データ加工を続ける場合はreset_index()でDataframeに変換するとよい。

```
>>> smr = df.groupby(['ken', ‘name’]).size().reset_index(name=‘count’)
```

データ加工のコツ（ダメな例）

```
df2 = pd.DataFrame()
for i, seri in df.iterrows():
   datetime_str0 = seri['date0'] + " " + seri['time0']
   dt0 = datetime.strptime(datetime_str0, "%Y-%m-%d %H:%M:%S")
   dt = dt0 + timedelta(hours=9)
   seri['date'] = dt.strftime("%Y-%m-%d")
   seri['time'] = dt.strftime("%H:%M:%S")
   df2 = df2.append(seri)
```

date0 time0による日時を9時間進めてdate timeを作成。

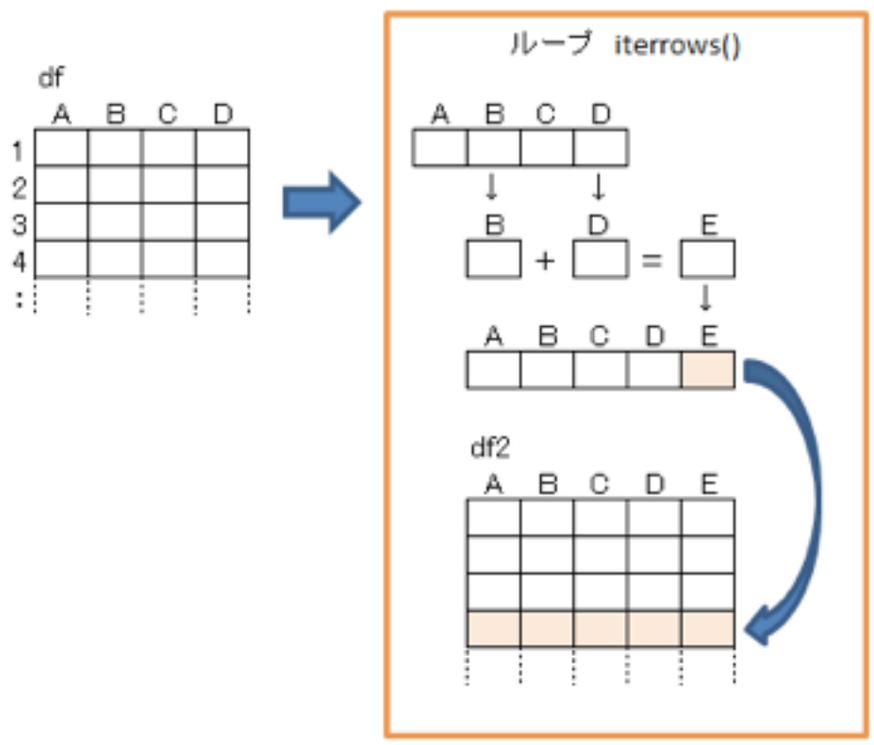

ループによる古風な処理

約2万件で約5分かかった。

データ加工のコツ（ちょっとましなダメな例）

```
date_ary = []
time_ary = []
for i, seri in df.iterrows():
   datetime_str0 = seri['date0'] + " " + seri['time0']
   dt0 = datetime.strptime(datetime_str0, "%Y-%m-%d %H:%M:%S")
   dt = dt0 + timedelta(hours=9)
   date_ary.append(dt.strftime("%Y-%m-%d"))
   time_ary.append(dt.strftime("%H:%M:%S"))
df['date'] = date_ary
df['time'] = time_ary
```

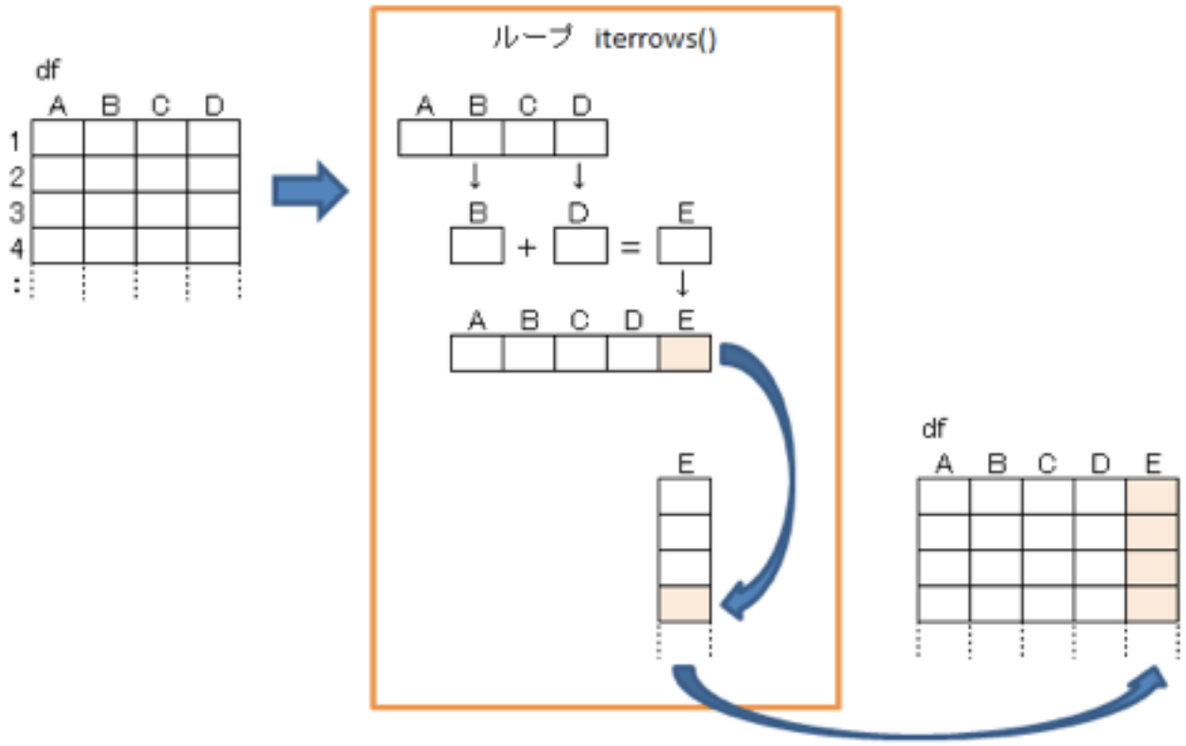

ループ処理ちょっと改良

約2万件で2.4秒。

データ加工のコツ（こうやる）

```
   df['datetime_str0'] = df['date0'] + " " + df['time0']
   df['datetime0'] = df['datetime_str0'].apply(lambda dts0: datetime.strptime(dts0, "%Y-%m-%d %H:%M:
%S"))
   df['datetime'] = df['datetime0'].apply(lambda dt0: dt0 + timedelta(hours=9))
   df['date'] = df['datetime'].apply(lambda dt: dt.strftime("%Y-%m-%d"))
   df['time'] = df['datetime'].apply(lambda dt: dt.strftime("%H:%M:%S"))
```

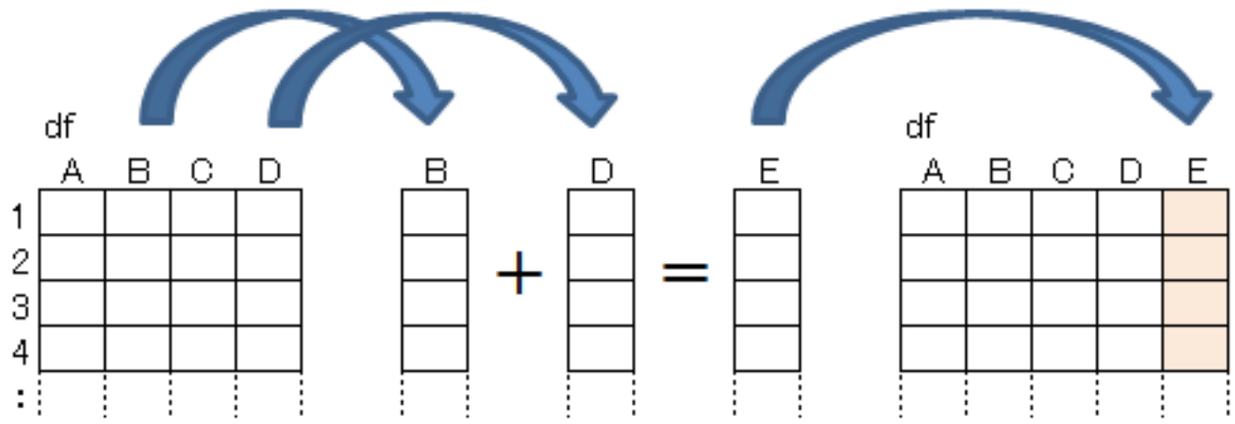

列ごとに処理

約2万件で1.4秒。

Appendix

```
>>> df.as_matrix()       # データフレームの配列化
>>> sr.values.flatten()  # シリーズの配列化
>>> df.reset_index(drop=True)      # インデクス番号の振り直し
>>> pd.read_csv(path, nrows=100)   # 先頭から100行だけCSVを読み込み
>>> df = pd.merge(df, df2, on='key')                 # 内部結合
>>> df = pd.merge(df, df2, on='key', how='left')   # 左側外部結合
>>> df = pd.merge(df, df2, on='key', how='outer')  # 完全外部結合
```